- **Objetivo del negocio**

Predecir el gasto promedio de los clientes para mejorar la personalización de ofertas y optimizar estrategias de marketing.

- **Tipo de problema**

Regresión supervisada, ya que buscamos predecir un valor numérico continuo (gasto).

- **Pipeline aplicado**

1. Carga de datos
2. Preprocesamiento (escalado + codificación)
3. División train/test
4. Entrenamiento de modelos
5. Evaluación con métricas
1. Optimización con GridSearch
2. Selección del mejor modelo

- **Modelos evaluados**

  - Regresión Lineal
  - KNN Regressor
  - Gradient Boosting

- **Métricas utilizadas**

  - MAE (Error absoluto medio)
  - RMSE (Error cuadrático medio)
  - R^2 (coeficiente de determinación)

- **Resultados**

(pon aquí la tabla que te imprime el código)

Ejemplo:	MAE	RMSE	R2
Linear	109.195058	124.207719	-0.060948
KNN	124.726047	144.595641	-0.437829
Boosting	117.419560	145.089027	-0.447658

🔹 **Modelo final elegido**

👉 **Gradient Boosting optimizado**

Justificación:

```
Linear    109.195058  124.207719 -0.060948
KNN       124.726047  144.595641 -0.437829
Boosting  117.419560  145.089027 -0.447658

Mejor modelo Boosting optimizado:
MAE: 115.20994011860402
RMSE: 132.91115012740966
R2: -0.21484188799107984
```

- Mejor rendimiento en métricas
- Captura relaciones no lineales
- Más robusto que modelos simples

🔹 **Conclusión**

El modelo desarrollado permite predecir el gasto de clientes con buena precisión, lo que puede ser utilizado para estrategias de marketing personalizado y segmentación de usuarios.